

Projection aléatoire : embeddings efficaces pour graphes hétérogènes

Présentation technique de 30 minutes

Nom Prénom

Institution

1^{er} juillet 2025

Jeu de données

- 28 702 auteurs
- 20 conférences
- 8 920 termes
- Types de relations : Auteur–Auteur, Auteur–Conférence, Auteur–Terme

Objectif

Apprendre des embeddings de dimension 256 préservant la sémantique afin de prédire de nouvelles collaborations.

Algorithme

- Pour chaque nœud : générer des marches aléatoires ("phrases")
- Entraîner Word2Vec (Skip-gram) sur ces séquences

Problèmes

- Coût computationnel et mémoire élevés
- Biais d'échantillonnage (structure globale manquante)
- Sensibilité aux hyperparamètres

- ❶ Créer une matrice aléatoire creuse R
- ❷ Appliquer directement les puissances de la matrice de voisinage M : MR , M^2R , M^3R
- ❸ Combiner ces vues avec des poids apprenables (softmax)

Theorem

Toute distribution aléatoire satisfaisant les hypothèses du lemme préserve les distances avec un facteur $(1 \pm \varepsilon)$ après projection dans $O(\log n)$ dimensions.

- 1 Projection aléatoire pondérée (paramètre α)
- 2 Construction / normalisation des méta-chemins (paramètre β)
- 3 Calcul itératif des puissances U_1, U_2, U_3
- 4 Combinaison linéaire $w_f \rightarrow$ embedding final
- 5 Perte : BCE + régularisation entropique

$$\mathcal{L} = \text{BCE}(\gamma - \lambda \|e_i - e_j\|^2, y_{ij}) + \lambda_{\text{entropy}} \sum_f w_f \log w_f$$

Gradients calculés par rétro-propagation ; mise à jour de $\theta_f, \lambda, \gamma$ avec Adam.

- AUC validation : 0,94
- 6 × plus rapide que Node2Vec
- Interprétable : les poids montrent l'importance des conférences (ACA)

- Projection aléatoire + puissances de matrice = embeddings efficaces
- Théorie garantie par Johnson–Lindenstrauss
- Scalabilité linéaire et support naturel des graphes hétérogènes

Merci de votre attention !